

Speech-Based German Declension Training System

202400420 Jisoo Jang¹

Table of Contents

- 0. Abstract
- 1. Introduction
- 2. System Design
- 3. Implementation & Results
- 4. Challenge & Iterations
- 5. Limitations & Future Work
- 6. Acknowledgement

0. Abstract

본 프로젝트는 한국외대 교수학습개발원 산하 튜터링 프로그램에서 진행되었던 <독일어 명사구 말하기 훈련>을 디지털 환경으로 구현한다. 이를 통해 실제로 학습 효과가 검증되었던 특정 언어 교육 과정을 튜터링 프로그램 종료 이후에도 지속 가능하고 접근성 좋게 제공하는 것을 목적으로 하며, '오디오', '텍스트', '시각' 세 가지 모달리티를 결합하여 디지털 환경의 장점을 극대화 함으로서 사용자에게 풍부한 학습 경험을 제공한다. 무료 배포 환경이라는 제약 조건에 맞춰 파라미터 사이즈 39M의 경량 ASR 모델인 Whisper-Tiny (OpenAI, 2024)²를 독일어 명사구 발화 인식이라는 특정 task에 맞게 fine-tuning 하였고, 평가 결과 WER와 DA score 간 Spearman's correlation 수치가 Whisper-Large 모델과 유사한 수준을 달성하여 (p: fine-tuned Tiny -0.49, Large -0.45), 더 큰 모델에 견줄 만한 성능의 task-specific ASR model fine-tuning을 해냈다는 의의를 지닌다. 해당 서비스는 현재 한국외국어대학교 독일어과 오스트리아도서관 공식 홈페이지를 통해 접속할 수 있으며, 추후 독일어 학습자들의 자율 학습 도구로서 활발히 이용 되기를 기대한다.

¹ Jisoo Jang (Department of German, Hankuk University of Foreign Studies): Project lead - digital implementation, model training, data collection & preprocessing, report writing

Jungi Hong (Department of German, Hankuk University of Foreign Studies): Original tutoring program design & operation (2026-1 HUFS Tutoring Program), linguistics consultation, data review. Certified at the C1 level by Goethe Institute.

Contributions solely by Jungi Hong are marked in *italics* and asterisks (*).



GitHub https://github.com/jsjang0104/Works/tree/main/project/2026-1_german_trainer



Service <https://huggingface.co/spaces/jsjang0104/german-declension-trainer>

² <https://huggingface.co/openai/whisper-tiny>

1. Introduction

1.1 문제 정의

굴절어인 독일어에서는 명사의 성, 수, 격에 따라 관사, 형용사, 명사의 어미가 모두 각각의 규칙으로 변화하는데, 이는 교착어인 한국어에는 없는 문법 체계이다. 이러한 특성으로 인해 한국어 화자에게 독일어는 학습 난이도가 매우 높으며, 특히 말하기에서 관사, 형용사, 명사가 모두 어미 변화되어 쓰이는 단위인 '명사구' 발화를 할 때 학습 병목 지점을 마주한다.

격	KR	EN	DE
주격 (~가)	한 작은 개(가)	a small dog (is)	ein kleiner Hund (ist)
속격 (~의)	한 작은 개(의)	(of) a small dog	eines kleinen Hundes
여격 (~에게)	한 작은 개(에게)	(to) a small dog	(zu) einem kleinen Hund
대격 (~를)	한 작은 개(를)	a small dog	einen kleinen Hund


▲ **Table 1. 격 변화에 따른 각 언어에서의 어미 변화 예시.** 한국어, 영어에서는 격에 따라 단어 형태가 변하지 않지만, 독일어에서는 기본 형태 [ein- klein- Hund-]로 출발하여 격에 따라 관사, 형용사, 명사의 형태 변화가 일어난다. (붉은 색 글씨로 표시) 또한 격 뿐만이 아니라 명사의 성, 수 그리고 관사 종류가 변화하면 변화 형태는 더욱 복잡하게 분화한다.

1.2 기존 방식의 한계

기존 디지털 언어 학습 플랫폼. 이러한 학습 병목을 해결하기 위해서는 형용사를 포함한 모국어 명사구를 즉각적으로 독일어로 번역하여 발화하는 연습이 필요하다. 하지만 현 시점에서는 적절한 학습 플랫폼이 부재한데, 대표적으로 외국어 학습 플랫폼인 듀오링고의 경우 독일어 작문을 위한 전반적인 연습 체계는 잘 갖추어져 있지만 상기 서술한 가장 큰 병목인 관사, 형용사, 명사 중심의 명사구 번역 및 발화 연습만 중점적으로 할 수 있는 방법은 없다.

한국외대 교수학습개발원 산하 2026-1 튜터링 프로그램 <독어수리마수리>. 교내 비교과 프로그램으로 진행되었던 <독어수리마수리> 튜터링 팀에서, 튜터 홍준기는 앞서 서술되었던 독일어 학습의 병목을 해결하고자 한국어 명사구를 독일어로 빠르게 번역하여 발화하는 내용의 교육을 진행하였으며, 이를 통해 실제로 튜티들의 독일어 명사구 발화에서의 정확성 및 속도가 눈에 띄게 개선되었다. 하지만 단기적이고 실시간으로 진행되는 튜터링 수업 특성 상 수업 내 문제 제시 및 정답 검수 과정은 오로지 튜터 홀로 진행할 수 밖에 없었으며, 다수의 튜티들을 대상으로 1:1로 돌아가며 진행되었기에 시간적 효율이 낮았다. 또한 튜터링 시간 외에는 튜티들이 이러한 방식의 명사구 즉각 발화 훈련을 개인적으로 연습할 방법이 없었다. 이전에 진행되었던 실제 튜터링 수업 영상은 다음 링크에서 확인할 수 있다:

<https://www.youtube.com/watch?v=9rvnFPQl2c8>



▲ Figure 1. <독어수리마수리> 튜터링 팀 정보. 한국외국어대학교 HUFSAbility 홈페이지 캡처 화면.

1.3 프로젝트 목표 및 의의

이러한 학습 병목 및 기본 튜터링 방법론의 한계를 극복하고자, 이번 프로젝트의 목표를 '기존 튜터링 프로그램에서 진행되었던 독일어 명사구 발화 훈련의 디지털 구현'으로 삼았다.


본 프로젝트는 다음과 같은 측면에서 의의를 가진다. 먼저 언어교육 **접근성** 측면에서, 기존 튜터링 방식이 갖던 한계를 자동화함으로써 학습자가 시간과 장소에 구애받지 않고 독립적으로 반복 연습할 수 있는 환경을 제공한다. 또한 경량 모델인 Whisper Tiny 를 독일어 명사구 발화라는 Task 에 맞게 fine-tuning 하여, Hugging Face 기반 무료 배포 환경에서도 잘 작동하게 하여 비용 부담을 최소화하였다. 이처럼 본 프로젝트는 실제 교육 현장에서 효과가 검증된 훈련방식을 디지털 환경으로 구현함으로써, 기존 튜터링 방식의 시간적, 공간적 제약을 극복하고 보다 많은 학습자가 검증된 훈련을 동일하게 경험할 수 있다는 점에서 의의를 가진다.

한편 **멀티모달 AI 활용** 측면에서는, 텍스트(문제 제시) · 음성(학습자 발화 입력) · 시각(정답 어미 변화 부 표시)의 세 가지 모달리티를 결합함으로써 사용자에게 단일 모달 방식 대비 더 풍부한 학습 경험을 제공한다. 또한 ASR 기술을 언어학적 규칙 기반 채점 로직과 결합한 설계는 외국어 학습 도구에서 AI 를 실용적으로 적용한 사례로서 의의가 있으며, 전체 과정을 AI 에게 전부 의존하는 방식이 아닌 규칙 기반 설계와 혼합하여 시스템의 효율성을 확보한다.

1.4 파이프라인

본 시스템의 전체 파이프라인은 다음과 같다. 먼저 시스템은 규칙 기반 설계를 통해 생성된 한국어 명사구를 화면에 제시하며, 학습자는 필요 시 해당 명사구의 독일어 단어 원형을 참고할 수 있다. 이후

학습자가 이를 독일어로 번역하여 발화하면, ASR 모델이 해당 음성을 텍스트로 변환한다. 변환된 텍스트는 규칙 기반 채점 로직과 대조되어 점수 및 피드백이 제공된다.



▲ Figure 2. System pipeline for Speech-based German Declension Training System.

2. System Design

2.1 단어 DB 및 규칙 기반 정답 생성 로직

단어 Data Base. 독일 공인 독일어 자격증을 발급하는 기관인 Goethe-Zertifikat 이 제공하는 A1³, A2⁴ level 단어장에 명시되어 있는 형용사 148 개, 명사 470 개를 사용하였으며, 관사로는 부정관사 (unbestimmter Artikel) 'ein-', 그리고 지시관사 (Demonstrativartikel) 'diese-'를 사용하였다. *다만 명사의 어미변화 분류를 나타내는 태그의 분류는 단어장에 기입되어 있던 규칙에서 더 세분화하였다.** 자세한 세분화 내역은 Appendix A 에서 확인할 수 있다.

정답 생성 로직. 본 프로젝트의 목적 중 하나인 사용자 접근성을 위한 비용 부담 최소화를 위하여 유료 (또는 limited) API 사용이 발생하지 않게 하였다. 그래서 훈련에 사용되는 한국어-독일어 텍스트 생성에서 AI 추론을 거치지 않고 모든 성,수,격에 따른 어미 변화 형태를 파이썬 스크립트 및 데이터 베이스에 전부 규칙 기반으로 구현하였다. 자세한 어미 변화 형태 구현 내역은 Appendix B 에서 확인할 수 있다.

³ https://www.goethe.de/pro/relaunch/prf/de/Goethe-Zertifikat_A1_Fit1_Wortliste.pdf

⁴ https://www.goethe.de/pro/relaunch/prf/de/Goethe-Zertifikat_A2_Wortliste.pdf

2.2 ASR Model Fine-tuning

2.2.1 Data

TTS Data. gTTS (Durette et al., 2024)⁵를 이용하여 Text-to-Speech Synthetic Data 를 제작하였다. 프로젝트 환경상 실제 한국인 발화 데이터를 모델 학습에 필요한만큼 많은 수량을 수집하기 어려워 opensource TTS model 을 통해 데이터를 3,610 건 랜덤 생성 후 (최대 API limit 기준), 이후 각 train, validation, test set 간 중복 데이터를 제거하여 최종적으로 train 2,888 건, validation 359 건, test 355 건을 확보하였다. 데이터 합성 과정에서는 다양성을 위하여 발화 속도 및 피치를 랜덤으로 설정하여 생성하였다.

Human Utterance Data. 위 TTS 합성 데이터는 발음 품질, 빠르기, 성별 (Pitch range), 배경 소음 등이 더욱 다양한 실제 inference 환경과 도메인 불일치가 존재한다. 따라서 이러한 간극을 보충하기 위하여 실제 외국어로서 독일어 (DaF, Deutsch als Fremdsprache)를 배우는 한국인 화자의 독일어 명사구 발화 데이터를 직접 수집하여 실제 추론 환경을 반영한 test data set 을 구축하였다. 해당 데이터셋은 총 한국인 화자의 독일어 발화 225 건으로 구성되어 있으며, 개별 화자는 모두 동일한 내용의 문장 25 건을 발화한다. 수집 환경은 실내 환경에서 개인 휴대폰 음성 녹음 어플리케이션을 사용하였으며, 수집된 원본 m4a 파일 (48,000Hz)은 Whisper 입력에 맞는 16,000Hz mono WAV 로 변환하여 사용하였다. 이후 *모든 개별 데이터는 three-point discrete Direct Assessment (scale 1,2,3)를 기준으로 발음 품질 평가 annotation 을 수행하였다.** 자세한 annotation principle 은 Appendix C 에서 확인할 수 있다.

Speaker ID	Gender	Number of Utterance	Average Pronunciation Score	German Proficiency Level
01 (annotator)	남	25	3.00	Advanced
04	여	25	2.56	Advanced
02	남	25	2.44	Advanced
03	남	25	2.36	Advanced
05	여	25	2.32	Advanced
06	여	25	2.00	Intermediate
08	남	25	1.68	Intermediate
09	남	25	1.24	Basic
10	남	25	1.16	Basic

▲ Table 2. Overview of the German Speech Dataset Collected from Korean Speakers.


⁵ <https://github.com/pndurette/gTTS>

2.2.2 Baseline

본 프로젝트에서는 비용 부담 최소화를 위하여 Hugging Face space 에 서비스를 배포할 것을 전제로 하였다. Hugging Face 가 제공하는 무료 space 에서는 하드웨어로 CPU basic (2 vCPU, 16GB RAM)만 지원하므로, 명사구 transcription task 특화 fine-tuning 을 진행할 ASR 모델로 경량 오픈 소스 모델인 Whisper-Tiny 를 선택하였다.

2.2.3 Fine-tuning

독일어 명사구 발화 transcription specific model 을 목적으로 fine-tuning 하였으며, TTS synthetic training data 2,888 개 및 validation data 359 개를 이용하여 학습시켰다. 주요 hyper parameter 설정은 learning rate $1e-5$, batch size 16, max epoch 20 이다. 이때 validation WER 이 3 회 이상 연속 개선되지 않을 경우 early stopping 을 하게끔 설정하였다. 학습 중에는 각 에포크 마다 Cross-Entropy Loss 및 WER 을 계산하여 경과를 추적하였다.



▲ **Figure 3. Whisper-tiny Fine tuning 과정에서의 학습 경과.** 학습은 에포크 1 에서 2 로 넘어가는 구간에서 loss 가 급격히 감소한 후 완만하게 수렴하는 양상을 보였다. 이후 early stopping 에 의해 epoch 8 에서 종료되었으며 최적 체크포인트로 epoch 5 의 가중치가 저장되었다. 최적 체크포인트 기준 train WER 0.03%, validation WER 0.554%에 도달하여 과적합 없이 안정적으로 학습이 진행되었다.

2.3 Evaluation

2.3.1 Evaluation Setting


Evaluation metric 으로는 WER (Word Error Rate)과 Log-Likelihood 를 이용하였다. WER 은 reference 와 모델 출력 hypothesis 간의 단어 단위 오류 (대치·삭제·삽입)를 측정한 값이고, Log-Likelihood 는 decoding 시 정답 텍스트 y 가 주어진 음성 데이터 x 에서 생성될 조건부 확률 $\log P(y|x)$ 를


추정한 값이다. WER 은 문자 단위 정확도를, Log-Likelihood 는 모델의 발화 수용도를 반영하므로 두 지표는 상호 보완적으로 존재한다.

평가 데이터로는 TTS synthetic test data 355 건, human utterance data 225 건으로 두 가지 데이터셋으로 진행하였으며, 특히 human data 에서는 annotation score 간의 correlation 을 함께 측정하였다.

2.3.2 TTS Data Result

해당 데이터로 평가한 Fine-tuned Whisper-tiny 는 baseline 대비 WER 1/19 수준 (WER 평균 19.81% → 1.22%), Log-Likelihood 0 에 근접한 수치 (-6.6460 → -0.0286)를 보여주며 독일어 명사구 도메인에 강하게 특화되었음을 보여주었다. 특히 baseline 은 음성의 단어 경계를 잘못 인식해 의미 없는 문장을 만들어내는 경향이 있었으나 fine-tuning 후 모델은 이를 정확한 명사구로 복원하였다. 예를 들어 잘못 인식된 'dieselibmbabies'가 정답인 'diese lieben babys'로, 잘못 인식된 'paula fenn'이 정답인 'fauler fan'으로 적절하게 개선되었다. 위 사례에서 볼 수 있듯 Baseline 의 핵심 문제는 단순 발음 오류가 아니라 독일어의 어휘 또는 형태소 자체를 모르는 것이었고, 파인튜닝을 통해 독일어 명사구 텍스트와 음성을 직접 학습함으로써 이러한 문제를 해결하였다. 특히 격변화 위주 명사구로 이루어진 학습 데이터의 특성이 즉각 반영되어, 이전에 baseline 이 독일어 명사구의 격변화 어미를 제대로 인식하지 못해 발생했던 오류 대부분이 fine-tuning 을 통해 해소되었다.







▲ **Figure 4.** (위) **Original Whisper-Tiny (baseline)** (아래) **Fine-tuned Whisper-Tiny**. gTTS synthetic data 로 평가한 Whisper-Tiny 의 fine-tuning 전후 성능 차이 비교. 위 아래 그래프들의 세로축 range 가 다름에 유의해야 한다.

2.3.3 Human Utterance Data Result


Figure 5~8 은 순서대로 Baseline Whisper-Tiny (Fine-tuning 없음), Fine-Tuned Whisper-Tiny, Whisper-Medium, Whisper-Large-V3 의 결과이며, 각 Figure 에서는 서로 다른 종류의 그래프 4 개가 병렬로 나열되어 있다. 각 Figure 의 첫 번째와 두번째 그래프는 개별 화자 (가로축)에 따른 WER 및 Log-Likelihood (세로축)이며 개별 화자들은 발화 품질의 DA score 평균 값에 따라 advanced (red) / intermediate (orange) / basic (blue)으로 발음 숙련도 그룹에 매핑되었다. 세번째 및 네번째 그래프는 225 건 발화 데이터 전체의 DA Score (1/2/3)와 모델이 출력해 낸 Log-Likelihood 및 WER 값의 상관관계 (Spearman's correlation)을 보여준다.




▲ **Figure 5.** Fine-tuning 전 Whisper-Tiny (39M). Human Utterance Data 로 평가.



▲ Figure 6. Fine-tuning 후 Whisper-Tiny (39M). Human Utterance Data 로 평가.



▲ Figure 7. Fine-tuning 을 진행하지 않은 Whisper-Medium (769M). Human Utterance Data 로 평가.



▲ Figure 8. Fine-tuning 을 진행하지 않은 Whisper-Large (1.55B). Human Utterance Data 로 평가.

전체 WER 비교. 전체 데이터셋에 대한 Overall WER 을 비교하면, baseline 인 Whisper-Tiny 는 72.15%로 가장 높은 오류율을 보였으나, fine-tuned Whisper-Tiny 는 29.78%로 절반 이하 수준까지 크게 개선되었다. 이는 같은 조건에서 실험한 Whisper-Large-V3 (29.19%)와 0.6%p 차이이다. 이는 domain-specific fine-tuning 이 모델 규모를 증가하며 성능 향상에 기여할 수 있음을 보여준다.

발음 숙련도 그룹별 비교. 발음이 비교적 정확한 Advanced 그룹에서는 Fine-tuned Whisper-Tiny 가 Whisper-Large-V3 보다 근소하게 높은 오류율을 보였으며 (19.20% vs 15.73%), 발음 식별 난이도가 높아지는 Intermediate 및 Basic 그룹에서는 Fine-Tuned Whisper-Tiny 가 오히려 더 낮은 WER 을 기록했다. (Intermediate: 31.33% vs 33.33%, Basic 54.67% vs 58.67%). 이는 Whisper-Tiny 가 fine-tuning 과정에서 독일어 명사구 발음 패턴에 충분히 적응하여 일반적인 목적으로 학습된 대형 모델보다 더 특화된 인식 능력을 갖추게 되었음을 보여준다.

발음 점수 (DA Score)와 WER 간 상관관계. 데이터 별 DA score 와 각 모델이 출력한 WER 간의 Spearman's Correlation 을 비교했을 때 Fine-tuned Whisper-Tiny 의 절댓값이 가장 크게 나타났으며, 이는 Whisper-Large-V3 보다 더 강한 상관관계를 보여 실제 인간 판단과 가장 민감하고 일관되게 반영한다는 것을 알 수 있다. 학습 프로그램에서 피드백의 핵심은 '모델의 인식 결과가 사용자의 실제 발음 수준을 얼마나 잘 변별해 내는가'에 있다는 점에서 이 결과는 사용자 피드백 도구로서 실용적으로 우수하다는 것을 나타낸다.

Log-Likelihood 비교. Log-Likelihood 에서의 Loss 는 절대적인 스케일이 각 모델 고유의 특성에 의해 좌우되기 때문에 4 개 case 의 절대값을 비교할 수는 없다. 하지만 Log-Likelihood 와 DA score 간의 Spearman's Correlation 은 rank 기반 통계량이라 변수 스케일 영향에서 자유롭다. 원본 Whisper-Tiny 는 LL 과 DA score 사이에 사실상 아무 관계가 없었는데 ($p=-0.023$), fine-tuning 후 $p=0.43$ 으로 뚜렷한 관계성이 포착된다. 이는 Whisper-Medium (0.229), Whisper-Large-V3 (0.151) 보다도 높은 수치로, fine-tuning 된 Tiny 모델이 문장에 부여하는 확신도가 실제 발음 수준을 유의미하게 반영했다고 해석할 수 있다.


3. Implementation & Results

Fine-tuned Whisper-tiny model 은 Hugging Face Hub 에 업로드 하였으며⁶, 서비스는 Gradio Framework 를 활용하여 Hugging Face free space 에 배포하였다.


첫 시작 화면 (Figure 9)에서는 사용자에게 간단한 서비스 소개와 함께 첫번째 퀴즈에서 AI 모델 로딩으로 인해 시간 지연이 발생할 수 있음을 안내한다. 사용자는 10, 20, 30 문항 중 희망하는 문제 개수를 선택할 수 있으며, 추가적으로 퀴즈 풀이에 참고할 수 있도록 *독일어 어미변화 규칙 자료**가 함께 제공된다.

이후 퀴즈 화면 (Figure 10)에서는 한국어 명사구가 제공되며, '힌트' 버튼 클릭 시 해당 명사구의 독일어 단어 어근이 표시된다. '녹음하기' 버튼을 누르면 녹음이 시작되는데, 브라우저 종류에 따라 마이크 사용 허용을 매 녹음마다 요청받을 수 있다. 이후 '채점하기' 버튼을 누르면 자동으로 녹음이 중지되고 채점 화면으로 전환 된다.

⁶ <https://huggingface.co/jsjang0104/whisper-tiny-german>



▲ Figure 9. 서비스 시작 화면




▲ Figure 10. 퀴즈 진행 중 독일어 발화 녹음 화면

발화 후 채점 단계 (Figure 11)에서는 fine-tuned whisper-tiny model 이 사용자 발화를 transcription 한 결과물을 reference text 와 비교하여 Log-Likelihood 기반 평가 결과 및 어미 변화 부분이 강조 표시된 정답 텍스트가 출력된다. 이때 평가 기준은 Table 3 에서 확인할 수 있다. 한편 모델 성능 평가 단계와 달리, 실제 서비스에서는 WER 을 사용자 평가 지표로 제공하지 않는다. Fine-tuned Whisper-tiny 모델

규모상 문자 단위 정확도에 한계가 있어 WER 을 사용자에게 직접적으로 제시하기에는 적절하지 않다고 판단했으며, 이에 평가 지표로 Log-Likelihood 만을 채택하였다.

Log-Likelihood	LL $\geq$ - 0.5	- 0.5 > LL $\geq$ -1.0	-1.0 > LL $\geq$ -2.0	-2.0 > LL
평가	매우 좋음	좋음	보통	개선 필요

▲ Table 3. Log-Likelihood 범위에 따른 평가



▲ Figure 11. 사용자 발화에 대한 개별 채점 결과 화면

선택한 문항 수가 모두 완료되면 최종 결과 화면이 표시되며 (Figure 12), 평균 Log-Likelihood 및 문항별 누적 결과가 표 형태로 제공된다.

시연 영상 (모바일 UI): https://youtube.com/shorts/N_hOnkEXRaM

다음 문제 →

🔥 5 / 10 통과 (평균 Log-Likelihood: -1.1511)

#	한국어	독일어 정답	Log-Likelihood	결과
1	이 직접적인 음료들이	diese direkten Getränke	-1.4090	◆ 보통
2	이 멍청한 동료들	dieser dumme Mitarbeiter	-0.9121	✔️ 좋음
3	이 텅 빈 공원들을	diese leeren Parks	-0.7324	✔️ 좋음
4	한 아쉬운 생일을	einen schaden Geburtstag	-1.0309	◆ 보통
5	한 깊은 축하에게	einem tiefen Glückwunsch	-0.4237	★ 매우 좋음
6	한 빠른 자전거의	eines schnellen Fahrrads	-1.7661	◆ 보통
7	이 아쉬운 태양들이	diese schaden Sonnen	-1.4179	◆ 보통
8	이 나쁜 달걀들을	diese schlechten Eier	-0.9813	✔️ 좋음
9	이 해로운 동물들	dieses schädlichen Tiers	-2.0783	❌ 개선 필요
10	이 멋진 손님들을	diese tollen Gäste	-0.7588	✔️ 좋음

처음으로

▲ Figure 12. 최종 누적 평가 결과 화면

4. Challenge & Iterations

4.1 규칙 기반 정답 생성 로직에서의 명사구 조합 문제

규칙 기반 생성 방식에서는 명사와 형용사의 조합이 의미적으로 어색해지는 경우가 발생하였다. 이를 완화하기 위해 명사 및 형용사에 도메인 매핑 (사람, 동물, 장소, 음식 등)을 부여하고 동일 도메인 내에서만 조합이 이루어지도록 하였으나, 일부 어색한 조합 출력은 여전히 존재하였다. 의미적으로 자연스러운 명사구를 완전히 보장하기 위해서는 신경망 기반 생성 모델을 활용하는 것이 이상적이나, 본 프로젝트는 저비용 및 높은 접근성을 핵심 목표로 설정하였기에 명사구 생성을 위한 추가적인 AI model 도입은 적합하지 않다고 판단하였다. 이에 대한 추가적인 논의는 추후 서비스 확장 시 이루어질 수 있다.

```

● (venv) jisoojang@Jisooui-MacBookAir grammar % python declension.py
한 높은 자매를
eine hohe Schwester
● (venv) jisoojang@Jisooui-MacBookAir grammar % python declension.py
한 무료의 기타의
einer kostenlosen Gitarre
● (venv) jisoojang@Jisooui-MacBookAir grammar % python declension.py
이 태어난 바나나에게
dieser geborenen Banane

```

▲ Figure 13. 어색한 조합의 명사구 출력 사례

4.2 TTS 합성 데이터와 실제 추론 데이터 도메인의 불일치

처음에는 TTS 합성 데이터로만 진행하려 했으나, 상기 서술되어 있듯 해당 데이터는 실제 발화 환경과 차이가 커 결과에 대해 충분한 신뢰를 주지 못할 수 있다고 판단하였다. 따라서 화자 및 환경 다양성을 반영할 수 있는 데이터를 직접 독일어과 지인들에게 부탁하여 추가로 확보하였고, 그렇게 확보한 data set 에 *발음 품질 human annotation* 을 추가⁷하여, 발음 품질 점수와 모델의 Log-Likelihood 및 WER 간의 correlation 값을 도출해냄으로써 TTS data 로 fine-tuning 된 모델의 실제 추론 환경에서의 robustness 를 검증해 내었다.

4.3 WER의 한계로 추가 평가 지표 도입

WER (Word Error Rate). 최초 evaluation metric 으로 채택되었던 WER 은 reference 와 모델 출력 hypothesis 간의 단어 단위 오류 건을 측정하여 baseline model 과 fine-tuned model 간 성능을 비교한다. 하지만 WER 은 reference 와 hypothesis 를 exact match 하는 그 특성상 매우 엄격한데, 실제 서비스 테스트 과정에서 사용자 발음에 문제가 없음에도 WER 이 심하게 측정되는 경우가 간혹 존재했다. 이는 transcription 과정에서 모델 성능의 한계로 인해 문자 단위 오류가 발생할 경우 단어 전체가 ‘오류’ 카운트로 계산되기 때문이며, 특히 독일어는 복합명사 및 합성어가 많아 이러한 경향성이 두드러진 것으로 해석된다.

Log-Likelihood Scoring. 위 경우 사용자 입장에서 동의할 수 없는 평가 피드백이 주어졌기 때문에, 이를 보완하기 위해 Log-Likelihood 를 추가 평가 지표로 채택하였다. Log-Likelihood 는 Whisper decoding 을 통해 정답 텍스트 y 가 주어진 음성 데이터 x 에서 생성될 조건부 확률 $\log P(y|x)$ 를 추정하는 값이다. 본 시스템은 자유 디코딩이 아닌 reference text 가 사전에 주어진 환경이므로, 발음 평가 지표로 per-token 평균 log-likelihood 를 사용하였다. 값이 0 에 가까울수록 발음이 정답에 근접함을 의미하며, 발음 품질을 continuous scalar score 점수로 표현할 수 있어 언어 학습 앱의 피드백 지표로 적합하다. 이에 따라 모델 성능 연구 및 평가 목적으로는 WER 과 Log-Likelihood 를 함께 활용하되, 실제 서비스에서 사용자에게 제공되는 피드백 지표로는 Log-Likelihood 만을 단독 채택하였다.

5. Limitations & Future Works

5.1 생성 어휘 수준의 범위 제한

본 시스템은 독일어 어미변화 학습에 병목을 겪는 초급 한국어 화자를 주요 사용자 대상으로 설정하였기에 현재 A1, A2 수준 어휘만을 사용하고 있다.⁷ 따라서 추후 더 높은 수준의 어휘를 단계적으로 추가함으로써 중급, 고급 학습자도 활용할 수 있도록 확장이 가능하며, 특정 도메인을

⁷ A1, A2 는 유럽언어공통참조기준(CEFR)의 초급 단계로 일상적인 기초 표현 및 간단한 의사소통이 가능한 수준에 해당한다.

선택적으로 필터링하는 기능을 도입한다면 학습자의 수준 및 목적에 맞는 맞춤형 연습 환경을 제공할 수 있을 것으로 기대된다.

5.2 향후 확장 가능성

현재 시스템은 한국어 문제 제시 및 독일어 정답 제공이 텍스트 형태로만 이루어진다. 추후 TTS 모델 API를 활용하여 이 텍스트들을 자연스러운 발음 및 인토네이션으로 출력하는 기능을 추가할 경우, 학습자가 정확한 발음을 확인할 수 있어 학습 효과가 더욱 향상될 것으로 기대된다.

6. Acknowledgements

본 프로젝트의 교육 방법론을 선제적으로 기획 및 운영하고, 독일어 언어학 관련 자문 및 발화 데이터 평가에 도움을 준 독일어과 홍준기 선배에게 감사를 표한다. 또한 독일어 발화 데이터셋 구축 시 각자 바쁜 사정이 있었음에도 기꺼이 참여해 준 독일어과 학우들인 하형욱, 조민규, 박민채, 김지원, 함태석, 남윤상, 최정우에게 깊이 감사드린다. 마지막으로, 본 프로젝트를 수행할 수 있는 기회를 제공해주신 멀티모달개론 담당 Language & AI 융합학부 최승택 교수님께도 감사드린다.

Appendix

A

기존 분류	세분화 사항	세분화 후
[-s]	<성별 구분 추가>	[m. -s], [n. -s], [f. -s]
[-]	<성별 구분 추가>	[m. -], [n. -]
[-e]	<성별 구분 추가>	[m. -e], [n. -e]
[-n]	<성별 구분 추가 + 유형 세분화>	[m./f. 형용사적], [m. 약], [m. 약+s], [m. 혼합], [n. 혼합], [f. 약]
[-en]	<성별 구분 추가 + 기존 유형에 통합/유형 재정의>	[m. 혼합](*옛 [-n] 카테고리에서 세분화된 기존 [m. 혼합]에 통합), [n. 혼합](*옛 [-n] 카테고리에서 세분화된 기존 [n. 혼합]에 통합), [f. 약](*옛 [-n] 카테고리에서 세분화된 기존 [f. 약]에 통합), [n. 혼합+LA]
[-er]	<성별 구분 추가>	[n. -er]
[-se]	<성별 구분 추가 + 유형 재정의>	[m. -e (단모음 명시)]
[-nen]	<성별 구분 추가 + 유형 재정의>	[f. 약 (단모음 명시)]
[ä-]	<성별 구분 추가 + 유형 재정의>	[m. -"], [n. -"]
[ä, -e]	<성별 구분 추가 + 유형 재정의>	[m. -e"], [f. -e"]
[ä, -er]	<성별 구분 추가 + 유형 재정의>	[m. -er"], [n. -er"]
[ü-]	<성별 구분 추가 + 기존 유형에 통합/유형 재정의>	[m. -"](*옛 [ä-] 카테고리에서 재정의된 기존 [m. -"]에 통합), [f. -"]
[ü, -e]	<성별 구분 추가 + 기존 유형에 통합>	[m. -e"](*옛 [ä, -e] 카테고리에서 재정의된 기존 [m. -e"]에 통합), [f. -"](*옛 [ä, -e] 카테고리에서 재정의된 기존 [f. -e"]에 통합)
[ü, -er]	<성별 구분 추가 + 기존 유형에 통합>	[n. -er"](*옛 [ä, -er] 카테고리에서 재정의된 기존 [n. -er"]에 통합)
[ö, -e]	<성별 구분 추가 + 기존 유형에 통합>	[m. -e"](*옛 [ä, -e] 카테고리에서 재정의된 기존 [m. -e"]에 통합)
[ö, -er]	<성별 구분 추가 + 기존 유형에 통합>	[n. -er"](*옛 [ä, -er] 카테고리에서 재정의된 기존 [n. -er"]에 통합)
[sg.]	<성별 구분 추가 + 유형 재정의>	[m. 단수전용], [n. 단수전용], [f. 단수전용], [m. -s (주로 단수전용)], [m. - (주로 단수전용)], [m. -e" (주로 단수전용)], [m. -e (주로 단수전용)], [n. 혼합 (주로 단수전용)], [n. -e (주로 단수전용)], [n. -er (주로 단수전용)], [n. -e (주로 단수전용)], [n. -" (주로 단수전용)], [f. -e"], [f. -e (주로 단수전용)], [f. 약 (주로 단수전용)]

▲ Table 4. 명사의 격변화 규칙을 나타내는 분류 태그를 기존 Goethe-Zertifikat 약식 버전에서 세분화하여 표기.

B

B.1

```
{
  "sg.1": "Abend",
  "sg.2": "Abends",
  "sg.3": "Abend",
  "sg.4": "Abend",
  "pl.1": "Abende",
  "pl.2": "Abende",
  "pl.3": "Abenden",
  "pl.4": "Abende",
  "gender": "masculine",
  "tag": "[m. -e]",
  "KR": "저녁"
},
```

▲ Figure 14. 명사 어미변화형 저장 예시. 위에서부터 순서대로 해당 단어의 단수 1 격, 단수 2 격, 단수 3 격, 단수 4 격, 복수 1 격, 복수 2 격, 복수 3 격, 복수 4 격, 단어의 성, 단어의 격변화 규칙 분류 태그, 한국어 뜻을 나타낸다.

B.2

```
ARTICLE = {
  'ein': {
    ('sg', 'masculine', 1): 'ein', ('sg', 'masculine', 2): 'eines', ('sg', 'masculine', 3): 'einem', ('sg', 'masculine', 4): 'einen',
    ('sg', 'neutral', 1): 'ein', ('sg', 'neutral', 2): 'eines', ('sg', 'neutral', 3): 'einem', ('sg', 'neutral', 4): 'einen',
    ('sg', 'feminine', 1): 'eine', ('sg', 'feminine', 2): 'einer', ('sg', 'feminine', 3): 'einer', ('sg', 'feminine', 4): 'eine',
  },
  'dieser': {
    ('sg', 'masculine', 1): 'dieser', ('sg', 'masculine', 2): 'dieses', ('sg', 'masculine', 3): 'diesem', ('sg', 'masculine', 4): 'diesen',
    ('sg', 'neutral', 1): 'dieses', ('sg', 'neutral', 2): 'dieses', ('sg', 'neutral', 3): 'diesem', ('sg', 'neutral', 4): 'dieses',
    ('sg', 'feminine', 1): 'diese', ('sg', 'feminine', 2): 'dieser', ('sg', 'feminine', 3): 'dieser', ('sg', 'feminine', 4): 'diese',
    ('pl', 'masculine', 1): 'diese', ('pl', 'masculine', 2): 'dieser', ('pl', 'masculine', 3): 'diesen', ('pl', 'masculine', 4): 'diese',
    ('pl', 'neutral', 1): 'diese', ('pl', 'neutral', 2): 'dieser', ('pl', 'neutral', 3): 'diesen', ('pl', 'neutral', 4): 'diese',
    ('pl', 'feminine', 1): 'diese', ('pl', 'feminine', 2): 'dieser', ('pl', 'feminine', 3): 'diesen', ('pl', 'feminine', 4): 'diese',
  },
},

ADJ_WEAK = { # der/dieser 뒤 약변화
  ('sg', 'masculine', 1): 'e', ('sg', 'masculine', 2): 'en', ('sg', 'masculine', 3): 'en', ('sg', 'masculine', 4): 'en',
  ('sg', 'neutral', 1): 'e', ('sg', 'neutral', 2): 'en', ('sg', 'neutral', 3): 'en', ('sg', 'neutral', 4): 'e',
  ('sg', 'feminine', 1): 'e', ('sg', 'feminine', 2): 'en', ('sg', 'feminine', 3): 'en', ('sg', 'feminine', 4): 'e',
  ('pl', 'masculine', 1): 'en', ('pl', 'masculine', 2): 'en', ('pl', 'masculine', 3): 'en', ('pl', 'masculine', 4): 'en',
  ('pl', 'neutral', 1): 'en', ('pl', 'neutral', 2): 'en', ('pl', 'neutral', 3): 'en', ('pl', 'neutral', 4): 'en',
  ('pl', 'feminine', 1): 'en', ('pl', 'feminine', 2): 'en', ('pl', 'feminine', 3): 'en', ('pl', 'feminine', 4): 'en',
},

ADJ_MIXED = { # ein 뒤 혼합변화
  ('sg', 'masculine', 1): 'er', ('sg', 'masculine', 2): 'en', ('sg', 'masculine', 3): 'en', ('sg', 'masculine', 4): 'en',
  ('sg', 'neutral', 1): 'es', ('sg', 'neutral', 2): 'en', ('sg', 'neutral', 3): 'en', ('sg', 'neutral', 4): 'es',
  ('sg', 'feminine', 1): 'e', ('sg', 'feminine', 2): 'en', ('sg', 'feminine', 3): 'en', ('sg', 'feminine', 4): 'e',
}
```

▲ Figure 15. 한국어-독일어 명사구 쌍 생성 python file 의 관사 및 형용사 어미변화 규칙 구현부.

C

<광범위한 기준>

: 발화된 어구의 의미를 독일인이 지체 없이 이해할 수 있는가

<세부 기준>

※ 지적 사항이 0 개일 시 3 점, 1~2 개일 시 2 점. 다만 강세 오류 있을 시 곧바로 1 점.

1. 단어 강세: 단어 강세가 올바른 음절에 실렸는가
2. 완전성: 누락된 음소나 다른 음소로 혼동되어 발화된 음소가 없는가
3. 모음 음질: 모음의 조음 위치가 전반적으로 정확한가 (포먼트 구성이 원어 화자의 것과 일치하는가)
4. 장·단모음 구별: 발화 지속 시간에 있어 장모음과 단모음의 차이가 명확한가
5. 리듬 구성: 강세가 일정 시간 간격으로 반복되는가
6. 자음 음질: 자음의 조음 위치 및 조음 방식이 전반적으로 정확한가 (포먼트, VOT, 음향 강도 등의 구성 및 변화 추이가 원어 화자의 것과 일치하는가)

▲ Human Utterance Data Annotation Principle